

Laboratorio 01: Clasificación ordinal de GDS con redes neuronales poco profundas

Asignatura: *Deep Learning* (2026-02)

Profesor: Dr. Juan Bekios Calfa

Gael Ortega

Escuela de Ingeniería

Universidad Católica del Norte

Ingeniería en Tecnologías de Información

`gael.ortega@alumnos.ucn.cl`

Johan Piñones

Escuela de Ingeniería

Universidad Católica del Norte

Ingeniería en Tecnologías de Información

`johan.pinones@alumnos.ucn.cl`

Resumen—Este informe presenta la implementación y evaluación de redes neuronales poco profundas para predecir etapas de deterioro cognitivo a partir de 15 respuestas binarias y 1119 registros. Se abordaron seis objetivos independientes: GDS y cinco reagrupaciones de sus etapas. Se compararon Softmax por defecto, Softmax con búsqueda de hiperparámetros, CORAL y CORAL con ponderación de clases mediante validación cruzada anidada, seleccionando por error absoluto medio (MAE) interno. CORAL mejoró el reconocimiento de algunas clases minoritarias, aunque con mayor error ordinal: en GDS_R4, el F1 macro pasó de 0,513 con Softmax optimizado a 0,600 con CORAL, mientras el MAE aumentó de 0,168 a 0,300. Como extensiones se evaluaron CORN, Softmax con arquitectura equiparada y la decisión por mediana. En GDS_R1, el Softmax equiparado alcanzó F1 macro 0,726 con argmax y 0,731 con mediana. Los resultados muestran que el orden, la arquitectura y la regla de decisión deben analizarse por separado, considerando tanto el desbalance como la distancia de los errores.

I. INTRODUCCIÓN

La escala Global Deterioration Scale (GDS) ordena siete etapas de deterioro cognitivo. Predecir estas etapas desde respuestas de un test de orientación es un problema de clasificación, pero sus clases también tienen un orden: confundir etapas vecinas no equivale a saltar varias etapas. Por ello, la exactitud por sí sola no describe toda la calidad de una predicción. El material del laboratorio plantea estudiar esta diferencia mediante redes neuronales poco profundas en PyTorch.

El archivo entregado contiene 1119 registros y 15 atributos binarios. Además de la escala original, incorpora cinco objetivos que agrupan sus etapas de distintas maneras. Cada objetivo define un experimento independiente: cambian el número de clases, sus frecuencias y el significado de un paso ordinal. El objetivo general fue implementar y evaluar modelos nominales y ordinales para los seis problemas.

Los objetivos específicos fueron:

- reproducir la línea base Softmax y seleccionar sus hiperparámetros dentro de cada entrenamiento externo;
- implementar CORAL, sus umbrales ordenados y una variante ponderada para estudiar el desbalance;

- comparar los métodos con métricas nominales y ordinales en los seis objetivos;
- estudiar CORN, la arquitectura equiparada y la decisión por mediana como extensiones; e
- interpretar los aciertos por clase y la distancia de los errores, considerando las limitaciones del conjunto de datos.

El desbalance hace especialmente exigente esta comparación: la escala original tiene siete clases, pero su etapa más extrema aparece solo dos veces. También existen perfiles de respuestas iguales con etiquetas diferentes. En consecuencia, un promedio global puede ocultar que una etapa rara no se reconoció, y ningún modelo determinista basado solo en estas 15 entradas puede separar todos los casos. Se conservaron los registros entregados y se examinaron tanto métricas de clase como medidas de distancia ordinal. La validación anidada mantuvo separada la elección de configuración de la evaluación final.

El trabajo se desarrolló en Python y PyTorch, con NumPy, pandas y scikit-learn para datos y evaluación, y un entorno definido con Conda. La pregunta central es si incorporar el orden mejora el desempeño frente a Softmax y bajo qué condiciones esa mejora implica un costo en otras métricas. El flujo sigue las fases de comprensión del problema y los datos, preparación, modelado y evaluación de CRISP-DM. Su alcance es experimental: se estudian modelos y limitaciones de los datos, sin desplegar un sistema de diagnóstico clínico.

II. MARCO TEÓRICO

II-A. *Redes poco profundas y clasificación nominal*

Un perceptrón multicapa (MLP) combina transformaciones afines y activaciones no lineales para aprender relaciones entre atributos. ReLU, $\max(0, z)$, permite representar interacciones entre respuestas binarias; estas entradas se cargan como números reales y no requieren una red especial. Dropout desactiva unidades durante el entrenamiento para regularizar, mientras

BatchNorm normaliza activaciones intermedias y aprende su escala y desplazamiento.

En clasificación nominal, la red produce K logits z_c . Softmax los transforma en probabilidades y la entropía cruzada penaliza la clase verdadera:

$$p_c = \frac{e^{z_c}}{\sum_{r=0}^{K-1} e^{z_r}}, \quad \mathcal{L}_{\text{CE}} = -\log p_y. \quad (1)$$

Esta pérdida distingue clases, pero no su distancia ordinal. En PyTorch, `CrossEntropyLoss` recibe directamente los logits. La decisión habitual, `argmax`, selecciona la clase más probable.

II-B. CORAL y consistencia ordinal

CORAL (*Consistent Rank Logits*) [0] convierte una etiqueta $y \in \{0, \dots, K-1\}$ en $K-1$ respuestas acumulativas $t_j = \mathbf{1}[y > j]$, donde $\mathbf{1}$ es la función indicadora. Un vector compartido proyecta la representación oculta a un puntaje $s(\mathbf{x})$; cada logit suma un sesgo b_j :

$$q_j = \sigma(s(\mathbf{x}) + b_j), \quad \hat{y} = \sum_{j=0}^{K-2} \mathbf{1}[q_j > 0.5]. \quad (2)$$

Con $b_0 \geq \dots \geq b_{K-2}$ se obtiene $q_0 \geq \dots \geq q_{K-2}$, coherente con $q_j = P(Y > j | \mathbf{x})$. El laboratorio impone este orden mediante separaciones positivas con `softplus` y suma acumulada. La pérdida utilizada promedia la entropía cruzada binaria (BCE) por umbral y muestra:

$$\mathcal{L}_{\text{CORAL}} = \frac{1}{N(K-1)} \sum_{i,j} \ell(t_{ij}, q_{ij}), \quad (3)$$

$$\ell(t, q) = -t \log q - (1-t) \log(1-q).$$

Las probabilidades de clase se recuperan por diferencias: $p_0 = 1 - q_0$, $p_c = q_{c-1} - q_c$ para clases intermedias y $p_{K-1} = q_{K-2}$. El orden evita probabilidades negativas, pero no garantiza una mejora predictiva.

II-C. Desbalance y número efectivo de muestras

La ponderación de Cui et al. [1] asigna a cada clase presente un peso bruto $w_c = (1 - \beta)/(1 - \beta^{n_c})$, donde n_c es su frecuencia de entrenamiento. Al aproximarse β a uno, el peso se acerca a $1/n_c$; con frecuencias grandes y β menor, las diferencias se atenúan. Los pesos normalizados multiplican la pérdida de cada muestra. Combinar esta corrección con muestreo ponderado puede sobrerepresentar dos veces las clases raras, por lo que se estudió únicamente la ponderación.

II-D. CORN y decisión por mediana

CORN (*Conditional Ordinal Regression for Neural networks*) [2] usa pesos de salida distintos y aprende condicionales: $r_0 = P(Y > 0 | \mathbf{x})$ y $r_j = P(Y > j | Y > j-1, \mathbf{x})$. La regla del producto obtiene acumuladas coherentes, $q_j = \prod_{k=0}^j r_k$. Cada subtarea se entrena solo con ejemplos que cumplen su condición, aumentando flexibilidad a costa de menos datos en los umbrales superiores.

Una distribución Softmax también admite una decisión ordinal: $\hat{y}_{\text{med}} = \min\{c : \sum_{r=0}^c p_r \geq 0.5\}$. Bajo las probabilidades

estimadas, una mediana minimiza el error absoluto esperado, mientras `argmax` minimiza el error de clasificación. Cambiar la decisión permite estudiar el efecto del criterio de inferencia sin volver a entrenar.

II-E. Métricas y validación anidada

F1 macro promedia el F1 de cada clase con igual peso; `balanced accuracy` promedia sus recalls. El MAE ordinal, $N^{-1} \sum_i |y_i - \hat{y}_i|$, mide pasos de error. QWK es el kappa ponderado cuadráticamente: penaliza distancias al cuadrado y corrige el acuerdo esperado a partir de las distribuciones marginales. Exactitud ± 1 y errores ≥ 2 distinguen fallos cercanos y lejanos. La validación anidada separa la selección interna de hiperparámetros de la evaluación externa, evitando usar las mismas observaciones para elegir y puntuar una configuración.

III. METODOLOGÍA

III-A. Datos y preparación

Se utilizó el archivo `15 atributos R0-R5.sav`, con 1119 filas, 15 indicadores binarios y seis columnas objetivo. ID identifica la fila y no se usó como predictor. No había valores faltantes. Para cada objetivo, sus clases originales se ordenaron y recodificaron a índices $0, \dots, K-1$ antes del entrenamiento. Las matrices de confusión muestran las etiquetas originales; por ejemplo, `GDS_R3` tiene etiquetas originales 1 y 3, pero se entrena como problema binario 0/1.

Las entradas se agrupan en orientación temporal (Día, Mes, Año y Estación), orientación espacial (País, Ciudad, CalleLugar y NumeroPiso) y los siete indicadores Miguel2, González2, Avenida2, Imperial2, A682, Caldera2 y Copiapo2. El archivo no documenta qué evento representa el valor 1 de cada indicador, por lo que no se interpretó su suma como una cantidad de aciertos. Se verificó su dominio $\{0, 1\}$ y se cargaron como `float32`, sin imputación ni escalado. La matriz de entrada tiene forma (1119, 15) y cada vector objetivo, forma (1119,).

Tabla I: Distribución completa de clases. Los conteos siguen el orden de las etiquetas indicadas.

Objetivo	Clases	Casos por clase
GDS	1-7	149 / 500 / 298 / 108 / 42 / 20 / 2
GDS_R1	1, 2, 3	947 / 150 / 22
GDS_R2	1, 2, 3	649 / 298 / 172
GDS_R3	1, 3	947 / 172
GDS_R4	1, 2, 3	149 / 906 / 64
GDS_R5	1, 2, 3	149 / 798 / 172

Las reagrupaciones conservan el orden, pero cambian la resolución del problema. Se verificó que las columnas del SAV coinciden con las agrupaciones del enunciado:

- **GDS_R1:** etapas 1-3 $\rightarrow$ 1; 4-5 $\rightarrow$ 2; 6-7 $\rightarrow$ 3.
- **GDS_R2:** etapas 1-2 $\rightarrow$ 1; 3 $\rightarrow$ 2; 4-7 $\rightarrow$ 3.
- **GDS_R3:** etapas 1-3 $\rightarrow$ 1; 4-7 $\rightarrow$ 3.
- **GDS_R4:** etapa 1 $\rightarrow$ 1; 2-4 $\rightarrow$ 2; 5-7 $\rightarrow$ 3.
- **GDS_R5:** etapa 1 $\rightarrow$ 1; 2-3 $\rightarrow$ 2; 4-7 $\rightarrow$ 3.

Cada columna se modeló por separado. Un paso de error corresponde a la escala recodificada de ese objetivo, no a una distancia clínica común entre todos los experimentos.

Existen perfiles de 15 respuestas idénticas con etiquetas distintas. En GDS se identificaron 97 perfiles ambiguos que abarcan 851 filas; en R1–R5 se encontraron 35, 73, 30, 60 y 70 perfiles, respectivamente. Un clasificador determinista que recibe solo esas entradas no puede asignar etiquetas distintas al mismo perfil. Se conservaron las observaciones, porque respuestas coincidentes pueden pertenecer a personas diferentes y eliminarlas alteraría el problema entregado.

III-B. Modelos y entrenamiento

Se denominó **Softmax (def.)** a la configuración por defecto y **Softmax (HP)** a la misma familia con búsqueda interna de hiperparámetros. La primera conserva la MLP $15 \rightarrow 32 \rightarrow K$, con ReLU y dropout 0,15. CORAL, CORAL + pesos, CORN y Softmax equiparado usan el bloque $15 \rightarrow H \rightarrow 16$: después de la primera capa se aplican ReLU, BatchNorm y dropout; después de la segunda, ReLU. La cabeza de salida determina los logits y la pérdida de cada método.

Todos los ajustes utilizaron Adam, lotes de 32 y 20 épocas. La grilla de la Tabla II conserva las cuatro configuraciones del código base; no es un producto cartesiano. CORAL + pesos cruza estas opciones con $\beta \in \{0,9; 0,99; 0,999\}$, obteniendo doce candidatos. Softmax (def.) usa la primera configuración sin búsqueda.

Tabla II: Grilla interna. La regularización por *weight decay* permanece fija en 10^{-4} .

Configuración	H	Dropout	Tasa de aprendizaje
Base	32	0,15	10^{-3}
Mayor ancho	64	0,15	10^{-3}
Mayor dropout	32	0,30	10^{-3}
Menor tasa	32	0,15	5×10^{-4}

Un benchmark previo de un ajuste de 20 épocas en un fold de GDS_R2, con tres repeticiones, dio medianas de 0,223 s en CPU y 0,428 s en GPU. Se eligió CPU con un hilo OpenMP para la corrida final. Esta decisión se basó en el costo medido para redes pequeñas, sin usar métricas predictivas del test externo.

III-C. Cómo se utilizó CORAL

La cabeza CORAL proyecta las 16 características ocultas a un escalar sin sesgo adicional. Un parámetro libre define b_0 y las diferencias se construyen como $b_j = b_0 - \sum_{r=1}^j \text{softplus}(d_r)$. Así, el orden se cumple desde el primer *forward*. La función BCE con logits recibe las salidas crudas y las etiquetas acumulativas; promedia primero los umbrales de cada muestra y luego las muestras del lote. La sigmoide se utiliza al interpretar probabilidades e inferir la clase.

Por ejemplo, con tres clases, la etiqueta original 2 corresponde al índice 1 y se codifica como $[1, 0]$. Los logits $[1, 3863; -1, 3863]$ producen acumuladas $[0, 8; 0, 2]$ y probabilidades de clase $[0, 2; 0, 6; 0, 2]$. Se supera un umbral y se

predice el índice 1. La BCE media de esta muestra es $-\log(0,8) \approx 0,2231$.

La variante ponderada multiplica esa pérdida por el peso de la clase. Con conteos ilustrativos $[2; 1; 1]$ y $\beta = 0,9$, los pesos normalizados son $[0,625; 1,1875; 1,1875]$; la pérdida del ejemplo pasa a $0,2231 \times 1,1875 \approx 0,2650$. En los experimentos, los conteos se calcularon con *inner-train* durante la búsqueda y se recalcularon con *outer-train* al re-entrenar. Una clase ausente recibe peso cero y el vector se normaliza a media uno entre las K clases.

III-D. Diseño de las extensiones

III-D1. CORN: Se sustituyó la cabeza CORAL por una capa lineal de $K - 1$ logits condicionales, conservando el bloque oculto, grilla y folds. Para el umbral j se seleccionan las muestras con $y \geq j$ y se usa como respuesta $1[y > j]$. La BCE se suma sobre todos los pares muestra–umbral elegibles y se divide por su cantidad total. Al evaluar, se aplica el producto acumulado de sigmoides antes de contar umbrales. Por ejemplo, condicionales $[0,8; 0,6; 0,9]$ producen acumuladas $[0,8; 0,48; 0,432]$ y predicción 1, no 3.

III-D2. Softmax con arquitectura equiparada: Se entrenó el mismo bloque oculto de CORAL/CORN con una cabeza de K logits y entropía cruzada. Este control permite comparar familias con igual representación oculta, en lugar de atribuir a la ordinalidad una diferencia debida al número de capas o a BatchNorm. Cada método selecciona sus propios hiperparámetros, por lo que se comparan procedimientos optimizados y no una ablación a configuración fija.

III-D3. Argmax frente a mediana: Sobre cada Softmax equiparado ya entrenado se aplicaron ambas reglas a las mismas probabilidades. Con $p = [0,40; 0,35; 0,25]$, argmax devuelve 0 y la mediana devuelve 1; los errores absolutos esperados según p son 0,85 y 0,65, respectivamente. La mediana reutiliza la configuración seleccionada con argmax. Por tanto, hay seis procedimientos de entrenamiento y siete filas de evaluación por objetivo.

III-E. Validación y métricas

Se aplicó validación cruzada anidada. Los objetivos R1–R5 usaron cinco folds externos y tres internos, estratificados. Dentro de cada entrenamiento externo se evaluó la grilla y se eligió el menor MAE interno medio, desempatando por mayor QWK interno. Luego se crearon modelo y optimizador nuevos, se reentrenó con todo el entrenamiento externo y se evaluó una vez en su test. Se conservaron las 20 épocas, sin *early stopping* ni selección de época a partir del test externo.

Los métodos compartieron los folds externos con semilla 42. Para el fold externo f e interno i , numerados desde 1, las semillas fueron $42 + f$ para la partición interna, $42 + 100f + i$ para el ajuste interno y $42 + 1000f$ para el reentrenamiento. Esto permite reconstruir las comparaciones y evita reutilizar parámetros aprendidos entre ajustes.

GDS requirió dos folds externos y dos internos porque la etapa 7 tiene solo dos casos. En la división interna se agruparon las etapas 6 y 7 únicamente para construir los

estratos; las etiquetas de entrenamiento, las predicciones y las métricas permanecieron en siete clases. Aun así, la clase 7 puede faltar en un entrenamiento interno. Esta excepción limita la estabilidad de su selección y se declara en vez de presentarla como una validación 5×3 ordinaria.

Se calcularon nueve métricas: accuracy, precisión macro, recall macro, F1 macro, balanced accuracy, MAE ordinal, QWK, exactitud dentro de ± 1 clase y proporción de errores de dos o más clases. Las métricas macro mantienen el vocabulario completo y asignan contribución cero cuando corresponde una división por cero. Las tablas muestran media $\pm$ desviación estándar poblacional entre folds externos; no son intervalos de confianza. Las matrices reúnen las predicciones fuera de muestra (OOF, *out-of-fold*) de todos los tests externos, con una predicción por fila y método. Sus conteos son agregados, mientras las métricas tabuladas se promedian por fold.

IV. RESULTADOS

IV-A. Comparación principal

La Tabla III resume la comparación principal en los seis objetivos. F1 macro describe el equilibrio entre clases y MAE la distancia media del error. Las nueve métricas de los cuatro métodos principales y de las extensiones aparecen por objetivo en el Apéndice A. Todas las cifras proceden de la corrida final validada.

Tabla III: Comparación principal por objetivo: media $\pm$ desviación externa. F1 se maximiza y MAE se minimiza.

Modelo	F1 macro $\uparrow$	MAE ordinal $\downarrow$
GDS		
Softmax (def.)	0,205 $\pm$ 0,019	0,535 $\pm$ 0,044
Softmax (HP)	0,222 $\pm$ 0,011	0,509 $\pm$ 0,019
CORAL	0,366 $\pm$ 0,019	0,709 $\pm$ 0,023
CORAL + pesos	0,294 $\pm$ 0,033	0,735 $\pm$ 0,036
GDS_R1		
Softmax (def.)	0,503 $\pm$ 0,054	0,109 $\pm$ 0,034
Softmax (HP)	0,505 $\pm$ 0,044	0,109 $\pm$ 0,030
CORAL	0,609 $\pm$ 0,088	0,124 $\pm$ 0,014
CORAL + pesos	0,629 $\pm$ 0,104	0,121 $\pm$ 0,018
GDS_R2		
Softmax (def.)	0,648 $\pm$ 0,038	0,295 $\pm$ 0,043
Softmax (HP)	0,653 $\pm$ 0,035	0,293 $\pm$ 0,043
CORAL	0,637 $\pm$ 0,027	0,298 $\pm$ 0,034
CORAL + pesos	0,636 $\pm$ 0,028	0,301 $\pm$ 0,030
GDS_R3		
Softmax (def.)	0,804 $\pm$ 0,041	0,090 $\pm$ 0,020
Softmax (HP)	0,804 $\pm$ 0,041	0,090 $\pm$ 0,020
CORAL	0,789 $\pm$ 0,048	0,097 $\pm$ 0,024
CORAL + pesos	0,789 $\pm$ 0,048	0,097 $\pm$ 0,024
GDS_R4		
Softmax (def.)	0,491 $\pm$ 0,045	0,169 $\pm$ 0,010
Softmax (HP)	0,513 $\pm$ 0,017	0,168 $\pm$ 0,005
CORAL	0,600 $\pm$ 0,024	0,300 $\pm$ 0,016
CORAL + pesos	0,588 $\pm$ 0,022	0,306 $\pm$ 0,023
GDS_R5		
Softmax (def.)	0,506 $\pm$ 0,016	0,225 $\pm$ 0,010
Softmax (HP)	0,510 $\pm$ 0,015	0,222 $\pm$ 0,009
CORAL	0,589 $\pm$ 0,037	0,346 $\pm$ 0,036
CORAL + pesos	0,589 $\pm$ 0,037	0,346 $\pm$ 0,036

IV-B. Reconocimiento de clases minoritarias y error ordinal

En GDS, CORAL sin pesos elevó F1 macro de 0,222 a 0,366 respecto de Softmax (HP), pero MAE subió de 0,509 a 0,709. El recall macro aumentó de 0,242 a 0,384, mientras la accuracy bajó de 0,554 a 0,391. Este contraste indica una redistribución de aciertos entre clases, no una mejora simultánea de todos los criterios. La etapa 7 aporta solo dos observaciones y limita la estabilidad del análisis de la cola extrema.

En GDS_R1, CORAL + pesos mejoró F1 macro frente a Softmax (HP), de 0,505 a 0,629, con un aumento de MAE de 0,109 a 0,121. La Fig. 1 permite interpretar el intercambio: Softmax no acertó ninguno de los 22 casos de clase 3 y CORAL ponderado acertó 18. Sin embargo, los aciertos de clase 2 bajaron de 78 a 31 sobre 150 casos. Recuperar la clase más rara benefició al promedio macro, aunque desplazó errores hacia la clase intermedia.

En GDS_R2, Softmax (HP) obtuvo F1 macro 0,653 y MAE 0,293, frente a 0,637 y 0,298 de CORAL. La ponderación apenas modificó F1 de CORAL, que pasó a 0,636. La separación es pequeña en relación con la variación entre folds y no se presenta como una diferencia estadísticamente demostrada.

En el objetivo binario GDS_R3, Softmax por defecto y con búsqueda empataron en F1 macro 0,804 y MAE 0,090. CORAL obtuvo 0,789 y 0,097. Al trabajar con índices 0/1, MAE equivale a $1 - \text{accuracy}$, la exactitud ± 1 siempre es uno y los errores graves siempre son cero. Estas dos últimas métricas no permiten distinguir modelos en este objetivo.

En GDS_R4, CORAL sin pesos elevó F1 macro de 0,513 a 0,600 respecto de Softmax con búsqueda, pero casi duplicó el MAE (0,168 a 0,300). La Fig. 2 permite ver el intercambio: CORAL acertó 80 de los 149 casos de clase 1, frente a ninguno en Softmax con búsqueda, a costa de trasladar más casos de la clase mayoritaria 2 hacia las vecinas. En GDS_R5 se repitió el patrón: F1 macro 0,589 frente a 0,510, con MAE 0,346 frente a 0,222.

IV-C. Acuerdo ordinal y errores graves

En GDS, CORAL aumentó QWK de 0,602 a 0,672 frente a Softmax (HP), pero también la proporción media de errores graves de 0,058 a 0,092. QWK compara desacuerdo cuadrático observado y esperado según las distribuciones marginales; por ello, no es equivalente a minimizar MAE ni la frecuencia de saltos. Un mejor kappa puede coexistir con más errores graves.

En GDS_R4, Softmax (HP) y CORAL no produjeron errores de dos pasos, aunque sus MAE fueron 0,168 y 0,300. El deterioro corresponde a una mayor cantidad de errores adyacentes. En GDS_R5, CORAL también introdujo una fracción media 0,004 de saltos de dos clases, frente a cero en Softmax (HP). Esto distingue dos formas de aumentar el error ordinal que accuracy por sí sola no describe.

IV-D. Extensión CORN: flexibilidad de la cabeza ordinal

CORN obtuvo MAE 0,487 en GDS, menor que 0,709 de CORAL y 0,509 de Softmax (HP). Sin embargo, su F1 macro 0,279 quedó por debajo del 0,366 de CORAL. La mayor




Figura 1: Matrices de confusión OOF de GDS_R1: Softmax con búsqueda (izquierda) y CORAL ponderado (derecha). Filas: clase real; columnas: clase predicha. Se usan las etiquetas originales 1, 2 y 3.




Figura 2: Matrices de confusión OOF de GDS_R4: Softmax con búsqueda (izquierda) y CORAL sin pesos (derecha). La clase original 2 concentra 906 de los 1119 casos.

flexibilidad condicional favoreció la distancia media de los errores en esta comparación, sin conservar toda la ganancia macro de CORAL.

En GDS_R1, CORN alcanzó F1 macro 0,709 y MAE 0,107, superando las medias de CORAL tanto sin pesos como ponderado. En R2 sus valores fueron 0,668 y 0,290. El beneficio no fue uniforme: en R4 igualó el MAE de Softmax (HP) a tres decimales (0,168), y en R5 obtuvo F1 0,500 y MAE 0,228, frente a 0,510 y 0,222 del baseline optimizado. CORN constituye una alternativa útil para ciertos objetivos, no un reemplazo universal de Softmax o CORAL.

IV-E. Control de arquitectura con Softmax equiparado

La Tabla IV muestra el caso R1, donde se observa con claridad el aporte del control arquitectónico. Cambiar del Softmax (HP) original al equiparado con argmax aumentó F1 macro de 0,505 a 0,726. Como ambos usan entropía cruzada y argmax, esta comparación evidencia la importancia de evaluar la familia arquitectónica y su selección interna antes de atribuir las diferencias a una cabeza ordinal.

Con el bloque oculto común, Softmax equiparado con argmax también obtuvo menor MAE que CORAL en GDS (0,483 frente a 0,709) y R2 (0,288 frente a 0,298). En R4

Tabla IV: Comparación ampliada en GDS_R1. Media $\pm$ desviación externa; las últimas dos filas comparten entrenamiento.

Modelo / decisión	F1 macro	MAE ordinal
Softmax (HP)	0,505 $\pm$ 0,044	0,109 $\pm$ 0,030
CORAL	0,609 $\pm$ 0,088	0,124 $\pm$ 0,014
CORAL + pesos	0,629 $\pm$ 0,104	0,121 $\pm$ 0,018
CORN	0,709 $\pm$ 0,043	0,107 $\pm$ 0,024
Softmax eq. (argmax)	0,726 $\pm$ 0,038	0,107 $\pm$ 0,022
Softmax eq. (mediana)	0,731 $\pm$ 0,038	0,105 $\pm$ 0,021

y R5, CORAL mantuvo mayor F1 macro, pero con mayor MAE. La arquitectura equiparada permite interpretar estas diferencias como comparaciones de cabeza, pérdida y decisión sobre una familia oculta común; la selección independiente de hiperparámetros impide aislar un único efecto causal.

IV-F. Decisión por mediana sobre el mismo modelo

La mediana redujo el MAE de Softmax equiparado frente a argmax en GDS (0,483 a 0,477), R1 (0,107 a 0,105), R2 (0,288 a 0,283) y R5 (0,223 a 0,222). En R3 produjo las mismas predicciones, como corresponde a un problema binario salvo posibles empates exactos; en R4 el MAE se mantuvo en 0,172 y F1 bajó de 0,505 a 0,503.

En R1, la mejora de F1 entre las dos decisiones equiparadas fue de aproximadamente 0,005, mucho menor que la diferencia de 0,221 entre Softmax (HP) y Softmax equiparado con argmax. Por tanto, la ganancia completa frente a la línea base no se debe a la mediana. Su aporte es una modificación de inferencia de bajo costo que puede favorecer MAE, condicionada por la calidad de las probabilidades estimadas.

V. DISCUSIÓN

La pregunta inicial no tiene una respuesta única por método. CORAL impone probabilidades acumuladas coherentes con el orden; era razonable evaluar si esa coherencia reducía también la distancia de los errores frente a Softmax. En algunos objetivos desbalanceados, CORAL cambió la asignación de predicciones hacia clases menos frecuentes. Esto puede elevar F1 macro o recall, pero también desplazar muchos casos de la clase mayoritaria y aumentar MAE. En GDS_R4 y GDS_R5, la mayor detección de clases minoritarias vino acompañada de un costo ordinal medible. Por ello, afirmar que una cabeza es “mejor” exige nombrar objetivo, métrica y tipo de error.

La ponderación por número efectivo tampoco produjo una ventaja general. En 24 de los 27 folds ponderados se eligió $\beta = 0,9$; para clases con muchos casos, sus pesos fueron casi iguales. La normalización tiene media uno entre clases, no necesariamente entre muestras, y modificar la escala de la pérdida también altera su relación con la regularización. En estos resultados, la ponderación mejoró F1 macro de CORAL en GDS_R1, fue prácticamente neutra en GDS_R2 y GDS_R5, y empeoró otras comparaciones. No hay evidencia de una corrección universal del desbalance.

Los controles ayudan a separar explicaciones, aunque no son una ablación causal completa. Softmax equiparado y CORAL comparten bloque oculto, pero cada método selecciona su

propia configuración interna y sus cabezas y pérdidas difieren. En cambio, argmax y mediana sí se aplican a las mismas probabilidades: su diferencia se atribuye a la regla de decisión. La mediana favorece el error absoluto esperado, lo que explica que pueda reducir MAE sin cambiar los parámetros del modelo.

La consistencia de CORAL se refiere al orden de las probabilidades acumuladas, no a que todas sus predicciones estén más cerca de la etiqueta real. El puntaje compartido restringe cómo se separan las clases en la representación oculta. CORN permite direcciones distintas por umbral y puede capturar relaciones más flexibles, pero sus sub tareas superiores reciben menos observaciones. En GDS, antes de dividir los datos, el último umbral condicional solo dispone de 22 casos de etapas 6–7, de los cuales dos son positivos. Esta escasez ayuda a entender por qué la flexibilidad adicional no garantiza reconocer mejor la etapa extrema.

Las agrupaciones también modifican qué errores son visibles. Al reunir varias etapas bajo una misma etiqueta desaparecen distinciones que el objetivo original sí exige. Por ello, el buen rendimiento binario en R3 refleja una tarea de menor resolución, no una superioridad clínica respecto de GDS. De manera similar, balanced accuracy y recall macro coinciden aquí al considerar las mismas clases con soporte; exactitud ± 1 y errores graves son complementarios. No constituyen evidencias independientes de mejora.

Hay límites importantes. GDS tiene solo dos casos de etapa 7 y dos folds externos; las métricas por clase rara son inestables. Se usó una sola semilla, por lo que las desviaciones entre folds no miden variación entre inicializaciones. Los perfiles de entrada idénticos con etiquetas distintas impiden clasificación perfecta desde estas variables. Tampoco se conoce el significado exacto del valor 1 en cada indicador ni se verificó dependencia entre filas. Finalmente, los objetivos reagrupados no tienen la misma dificultad ni conservan idéntica distancia clínica entre clases; el menor MAE de GDS_R3 no demuestra superioridad sobre un modelo de GDS de siete etapas.

El análisis de perfiles ambiguos describe una limitación de las entradas observadas, no un límite poblacional de generalización. Además, los folds se construyeron por fila y los seis objetivos corresponden a las mismas personas: no son seis conjuntos de datos independientes. La evidencia permite discutir tendencias dentro de cada tarea, pero una evaluación con otras semillas o una muestra externa sería necesaria para determinar su estabilidad.

VI. CONCLUSIONES

Se implementó y evaluó la comparación solicitada de Softmax fijo, Softmax con búsqueda interna, CORAL y CORAL ponderado en los seis objetivos, con métricas nominales y ordinales y separación entre selección interna y evaluación externa. El laboratorio cumplió su objetivo de estudiar cómo cambia el comportamiento predictivo cuando se incorpora el orden a una red poco profunda.

El resultado principal fue un intercambio entre reconocimiento de clases minoritarias y error ordinal. En R4, CORAL

reconoció 80 de 149 casos de clase 1 que Softmax (HP) no acertó, elevando F1 macro de 0,513 a 0,600, pero aumentando MAE de 0,168 a 0,300. La ponderación por número efectivo tampoco ofreció un beneficio sistemático: mejoró F1 de CORAL en R1, fue casi neutra en R2 y R5 y lo redujo en GDS y R4.

Las extensiones mostraron que la comparación no debe reducirse al nombre de la cabeza. CORN obtuvo un equilibrio favorable en R1, con F1 macro 0,709 y MAE 0,107, pero no superó al baseline en todos los objetivos. Softmax equiparado alcanzó F1 0,726 en esa tarea antes de cambiar la decisión; la mediana lo elevó a 0,731 y redujo ligeramente MAE. Esto distingue el aporte de la familia arquitectónica del ajuste de inferencia, y evita atribuir toda la mejora a la ordinalidad.

Desde el punto de vista metodológico, el laboratorio permitió conectar logits, pérdidas, probabilidades y reglas de decisión con una evaluación reproducible. Mantener la búsqueda dentro de cada entrenamiento externo, conservar el eje completo de clases y analizar predicciones OOF permitió interpretar fallos que quedaban ocultos en accuracy. La utilidad del enfoque reside en hacer explícito qué errores se reducen y cuáles aumentan al modificar el modelo.

Como trabajo futuro, sería razonable estudiar estabilidad entre semillas y disponer de más ejemplos de etapas extremas antes de extraer conclusiones clínicas. Los resultados actuales describen el rendimiento de este protocolo y este conjunto de datos; no justifican usar el modelo como diagnóstico.

VII. CÓDIGO Y REPRODUCIBILIDAD

VII-A. Organización y bloque principal de CORAL

La solución conserva una estructura modular. El archivo `main.py` coordina entrenamiento, búsqueda y validación. En `src/`, la configuración se centraliza en `config.py`; los datos y folds se preparan en `data_loader.py` y `preprocessing.py`. Las redes, pérdidas e inferencia se implementan en `models.py`, `losses.py` y `ordinal.py`, conectados por `methods.py`. Las métricas y salidas se generan en `evaluation.py` y `reporting.py`.

El Código 1 muestra el núcleo de `labels_to_levels`. La comparación por difusión transforma un vector de B etiquetas en una matriz $B \times (K - 1)$: cada columna responde si la etiqueta supera su umbral. Por ejemplo, el índice 1 entre tres clases genera $[1, 0]$.

```
1 thresholds = torch.arange(
2     num_classes - 1, device=labels.device
3 )
4 levels = (labels[:, None] > thresholds).to(
5     torch.float32
6 )
```

Código 1: Codificación acumulativa de una etiqueta para CORAL

VII-B. Ejecución y buenas prácticas

El código y los resultados están disponibles en:

<https://github.com/Gael-OC/DL-2026-02-L01>

El SAV debe ubicarse en `dataset/`; no se versiona. El Código 2 instala el entorno, ejecuta las pruebas y reproduce el protocolo desde la raíz del proyecto en una carpeta nueva. Se aplicaron semillas explícitas, reinicio de modelos y optimizadores por ajuste, pesos calculados solo con entrenamiento y separación entre selección y evaluación. Las opciones efectivas, configuraciones elegidas y predicciones OOF quedan asociadas a la corrida.

```
1 conda env create -f environment.yml
2 conda activate lab_pytorch
3 python -m unittest discover -s tests -q
4
5 OMP_NUM_THREADS=1 MPLBACKEND=Agg \
6 python main.py \
7     --data-path 'dataset/15 atributos R0-R5.sav' \
8     --all-targets \
9     --methods softmax_fixed softmax_hp \
10     coral coral_weighted corn softmax_matched \
11     --outer-folds 5 --inner-folds 3 \
12     --gds-outer-folds 2 --gds-inner-folds 2 \
13     --epochs 20 --batch-size 32 --seed 42 \
14     --device cpu \
15     --output-dir results/reproduccion_informe
```

Código 2: Pruebas y reproducción de la corrida final

La corrida final terminó sin fallos: 42 filas de resultados, 189 registros de configuración por fold, 46 998 predicciones OOF y 42 matrices agregadas. Se verificaron 1119 índices únicos por combinación de método y objetivo, probabilidades válidas y concordancia entre matrices y predicciones. La verificación registrada del código reportó 30 pruebas automatizadas satisfactorias. El servidor utilizó Python 3.10.21, PyTorch 2.14.0, NumPy 2.2.6, pandas 2.3.3, scikit-learn 1.7.2 y pyreadstat 1.3.6.

W. Cao, V. Mirjalili y S. Raschka, “Rank consistent ordinal regression for neural networks with application to age estimation,” *Pattern Recognition Letters*, vol. 140, pp. 325–331, 2020.

REFERENCIAS

- [1] Y. Cui, M. Jia, T.-Y. Lin, Y. Song y S. Belongie, “Class-Balanced Loss Based on Effective Number of Samples,” en *CVPR*, pp. 9268–9277, 2019.
- [2] X. Shi, W. Cao y S. Raschka, “Deep Neural Networks for Rank-Consistent Ordinal Regression Based On Conditional Probabilities,” arXiv:2111.08851, 2021.

APÉNDICE A

TABLAS COMPLETAS POR OBJETIVO

Las Tablas V–X incluyen los cuatro métodos principales y las tres filas de evaluación adicionales, con modelos en filas y métricas en columnas. Cada celda contiene media $\pm$ desviación estándar poblacional entre folds externos. Se abrevia únicamente *equiparado* como “eq.” para los dos decodificadores del mismo Softmax.

Acc. es accuracy; Prec., Rec. y F1 son promedios macro; BalAcc es balanced accuracy; QWK es kappa ponderado cuadráticamente; Acc. ± 1 admite un paso de error y Err. ≥ 2 representa saltos de al menos dos pasos. MAE y Err. ≥ 2 se minimizan; las demás métricas se maximizan. La comparación se realiza dentro de cada objetivo.

Tabla V: Resultados completos para GDS: dos folds externos.

Modelo	Acc.	Prec.	Rec.	F1	BalAcc	MAE	QWK	Acc. $\pm$ 1	Err. $\geq$ 2
Softmax (def.)	0,541 $\pm$ 0,034	0,214 $\pm$ 0,005	0,224 $\pm$ 0,021	0,205 $\pm$ 0,019	0,224 $\pm$ 0,021	0,535 $\pm$ 0,044	0,534 $\pm$ 0,070	0,936 $\pm$ 0,002	0,064 $\pm$ 0,002
Softmax (HP)	0,554 $\pm$ 0,023	0,211 $\pm$ 0,005	0,242 $\pm$ 0,014	0,222 $\pm$ 0,011	0,242 $\pm$ 0,014	0,509 $\pm$ 0,019	0,602 $\pm$ 0,017	0,942 $\pm$ 0,006	0,058 $\pm$ 0,006
CORAL	0,391 $\pm$ 0,016	0,416 $\pm$ 0,019	0,384 $\pm$ 0,024	0,366 $\pm$ 0,019	0,384 $\pm$ 0,024	0,709 $\pm$ 0,023	0,672 $\pm$ 0,007	0,908 $\pm$ 0,006	0,092 $\pm$ 0,006
CORAL + pesos	0,373 $\pm$ 0,027	0,335 $\pm$ 0,030	0,434 $\pm$ 0,018	0,294 $\pm$ 0,033	0,434 $\pm$ 0,018	0,735 $\pm$ 0,036	0,683 $\pm$ 0,002	0,903 $\pm$ 0,010	0,097 $\pm$ 0,010
CORN	0,559 $\pm$ 0,009	0,294 $\pm$ 0,013	0,286 $\pm$ 0,004	0,279 $\pm$ 0,001	0,286 $\pm$ 0,004	0,487 $\pm$ 0,003	0,676 $\pm$ 0,007	0,958 $\pm$ 0,006	0,042 $\pm$ 0,006
Softmax eq. (argmax)	0,565 $\pm$ 0,025	0,346 $\pm$ 0,004	0,338 $\pm$ 0,021	0,317 $\pm$ 0,001	0,338 $\pm$ 0,021	0,483 $\pm$ 0,017	0,696 $\pm$ 0,018	0,958 $\pm$ 0,008	0,042 $\pm$ 0,008
Softmax eq. (mediana)	0,567 $\pm$ 0,024	0,372 $\pm$ 0,027	0,343 $\pm$ 0,034	0,329 $\pm$ 0,018	0,343 $\pm$ 0,034	0,477 $\pm$ 0,018	0,697 $\pm$ 0,018	0,960 $\pm$ 0,006	0,040 $\pm$ 0,006

Tabla VI: Resultados completos para GDS_R1: cinco folds externos.

Modelo	Acc.	Prec.	Rec.	F1	BalAcc	MAE	QWK	Acc. $\pm$ 1	Err. $\geq$ 2
Softmax (def.)	0,892 $\pm$ 0,035	0,516 $\pm$ 0,058	0,495 $\pm$ 0,051	0,503 $\pm$ 0,054	0,495 $\pm$ 0,051	0,109 $\pm$ 0,034	0,613 $\pm$ 0,111	0,999 $\pm$ 0,002	0,001 $\pm$ 0,002
Softmax (HP)	0,892 $\pm$ 0,030	0,517 $\pm$ 0,049	0,497 $\pm$ 0,041	0,505 $\pm$ 0,044	0,497 $\pm$ 0,041	0,109 $\pm$ 0,030	0,615 $\pm$ 0,094	0,999 $\pm$ 0,002	0,001 $\pm$ 0,002
CORAL	0,880 $\pm$ 0,011	0,709 $\pm$ 0,085	0,659 $\pm$ 0,077	0,609 $\pm$ 0,088	0,659 $\pm$ 0,077	0,124 $\pm$ 0,014	0,627 $\pm$ 0,053	0,996 $\pm$ 0,003	0,004 $\pm$ 0,003
CORAL + pesos	0,883 $\pm$ 0,015	0,741 $\pm$ 0,109	0,673 $\pm$ 0,079	0,629 $\pm$ 0,104	0,673 $\pm$ 0,079	0,121 $\pm$ 0,018	0,636 $\pm$ 0,061	0,996 $\pm$ 0,003	0,004 $\pm$ 0,003
CORN	0,895 $\pm$ 0,024	0,761 $\pm$ 0,059	0,697 $\pm$ 0,053	0,709 $\pm$ 0,043	0,697 $\pm$ 0,053	0,107 $\pm$ 0,024	0,672 $\pm$ 0,062	0,998 $\pm$ 0,004	0,002 $\pm$ 0,004
Softmax eq. (argmax)	0,894 $\pm$ 0,022	0,791 $\pm$ 0,070	0,721 $\pm$ 0,058	0,726 $\pm$ 0,038	0,721 $\pm$ 0,058	0,107 $\pm$ 0,022	0,679 $\pm$ 0,059	0,999 $\pm$ 0,002	0,001 $\pm$ 0,002
Softmax eq. (mediana)	0,895 $\pm$ 0,021	0,795 $\pm$ 0,067	0,725 $\pm$ 0,060	0,731 $\pm$ 0,038	0,725 $\pm$ 0,060	0,105 $\pm$ 0,021	0,685 $\pm$ 0,056	0,999 $\pm$ 0,002	0,001 $\pm$ 0,002

Tabla VII: Resultados completos para GDS_R2: cinco folds externos.

Modelo	Acc.	Prec.	Rec.	F1	BalAcc	MAE	QWK	Acc. $\pm$ 1	Err. $\geq$ 2
Softmax (def.)	0,726 $\pm$ 0,036	0,682 $\pm$ 0,042	0,635 $\pm$ 0,040	0,648 $\pm$ 0,038	0,635 $\pm$ 0,040	0,295 $\pm$ 0,043	0,685 $\pm$ 0,059	0,979 $\pm$ 0,007	0,021 $\pm$ 0,007
Softmax (HP)	0,726 $\pm$ 0,036	0,687 $\pm$ 0,039	0,638 $\pm$ 0,038	0,653 $\pm$ 0,035	0,638 $\pm$ 0,038	0,293 $\pm$ 0,043	0,687 $\pm$ 0,059	0,980 $\pm$ 0,007	0,020 $\pm$ 0,007
CORAL	0,729 $\pm$ 0,023	0,681 $\pm$ 0,030	0,640 $\pm$ 0,030	0,637 $\pm$ 0,027	0,640 $\pm$ 0,030	0,298 $\pm$ 0,034	0,687 $\pm$ 0,056	0,973 $\pm$ 0,012	0,027 $\pm$ 0,012
CORAL + pesos	0,723 $\pm$ 0,017	0,665 $\pm$ 0,026	0,642 $\pm$ 0,031	0,636 $\pm$ 0,028	0,642 $\pm$ 0,031	0,301 $\pm$ 0,030	0,692 $\pm$ 0,058	0,976 $\pm$ 0,014	0,024 $\pm$ 0,014
CORN	0,726 $\pm$ 0,034	0,708 $\pm$ 0,041	0,645 $\pm$ 0,041	0,668 $\pm$ 0,041	0,645 $\pm$ 0,041	0,290 $\pm$ 0,037	0,687 $\pm$ 0,046	0,985 $\pm$ 0,005	0,015 $\pm$ 0,005
Softmax eq. (argmax)	0,732 $\pm$ 0,026	0,706 $\pm$ 0,018	0,647 $\pm$ 0,031	0,667 $\pm$ 0,026	0,647 $\pm$ 0,031	0,288 $\pm$ 0,028	0,686 $\pm$ 0,044	0,980 $\pm$ 0,006	0,020 $\pm$ 0,006
Softmax eq. (mediana)	0,733 $\pm$ 0,037	0,715 $\pm$ 0,035	0,655 $\pm$ 0,044	0,677 $\pm$ 0,041	0,655 $\pm$ 0,044	0,283 $\pm$ 0,039	0,693 $\pm$ 0,051	0,984 $\pm$ 0,007	0,016 $\pm$ 0,007

A-A. Procedencia y archivos de respaldo

El directorio docs/resultados/ contiene:

- resultados.csv: métricas sin redondear.
- configuraciones_folds.csv: parámetros elegidos en cada fold externo.
- MANIFIESTO.md: procedencia de la corrida del 23/09/2026, entorno y huellas del código y del SAV.

Las columnas base_* del resumen describen la referencia inicial; los hiperparámetros seleccionados se consultan por fold.

La copia ejecutada en el servidor no contenía metadatos Git, por lo que la procedencia se documentó con hashes de archivos. Después de la corrida solo se abrevió el nombre visible de CORN en las tablas públicas; no cambiaron sus predicciones ni métricas. Los artefactos por fold y las predicciones individuales se reconstruyen con el comando del Código 2 y se guardan en results/.

Tabla VIII: Resultados completos para GDS_R3: cinco folds externos. La recodificación binaria hace que $\text{Acc.} \pm 1 = 1$ y $\text{Err.} \geq 2 = 0$.

Modelo	Acc.	Prec.	Rec.	F1	BalAcc	MAE	QWK	Acc. ± 1	Err. ≥ 2
Softmax (def.)	0,910 $\pm$ 0,020	0,857 $\pm$ 0,050	0,771 $\pm$ 0,037	0,804 $\pm$ 0,041	0,771 $\pm$ 0,037	0,090 $\pm$ 0,020	0,610 $\pm$ 0,081	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax (HP)	0,910 $\pm$ 0,020	0,857 $\pm$ 0,050	0,771 $\pm$ 0,037	0,804 $\pm$ 0,041	0,771 $\pm$ 0,037	0,090 $\pm$ 0,020	0,610 $\pm$ 0,081	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
CORAL	0,903 $\pm$ 0,024	0,841 $\pm$ 0,065	0,757 $\pm$ 0,042	0,789 $\pm$ 0,048	0,757 $\pm$ 0,042	0,097 $\pm$ 0,024	0,580 $\pm$ 0,096	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
CORAL + pesos	0,903 $\pm$ 0,024	0,841 $\pm$ 0,065	0,757 $\pm$ 0,042	0,789 $\pm$ 0,048	0,757 $\pm$ 0,042	0,097 $\pm$ 0,024	0,580 $\pm$ 0,096	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
CORN	0,904 $\pm$ 0,025	0,838 $\pm$ 0,062	0,762 $\pm$ 0,058	0,791 $\pm$ 0,059	0,762 $\pm$ 0,058	0,096 $\pm$ 0,025	0,584 $\pm$ 0,116	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax eq. (argmax)	0,907 $\pm$ 0,022	0,853 $\pm$ 0,056	0,760 $\pm$ 0,042	0,795 $\pm$ 0,048	0,760 $\pm$ 0,042	0,093 $\pm$ 0,022	0,593 $\pm$ 0,095	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax eq. (mediana)	0,907 $\pm$ 0,022	0,853 $\pm$ 0,056	0,760 $\pm$ 0,042	0,795 $\pm$ 0,048	0,760 $\pm$ 0,042	0,093 $\pm$ 0,022	0,593 $\pm$ 0,095	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000

Tabla IX: Resultados completos para GDS_R4: cinco folds externos.

Modelo	Acc.	Prec.	Rec.	F1	BalAcc	MAE	QWK	Acc. ± 1	Err. ≥ 2
Softmax (def.)	0,831 $\pm$ 0,010	0,575 $\pm$ 0,053	0,473 $\pm$ 0,039	0,491 $\pm$ 0,045	0,473 $\pm$ 0,039	0,169 $\pm$ 0,010	0,235 $\pm$ 0,058	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax (HP)	0,832 $\pm$ 0,005	0,544 $\pm$ 0,020	0,507 $\pm$ 0,021	0,513 $\pm$ 0,017	0,507 $\pm$ 0,021	0,168 $\pm$ 0,005	0,283 $\pm$ 0,032	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
CORAL	0,700 $\pm$ 0,016	0,580 $\pm$ 0,017	0,665 $\pm$ 0,044	0,600 $\pm$ 0,024	0,665 $\pm$ 0,044	0,300 $\pm$ 0,016	0,396 $\pm$ 0,032	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
CORAL + pesos	0,695 $\pm$ 0,023	0,567 $\pm$ 0,022	0,656 $\pm$ 0,031	0,588 $\pm$ 0,022	0,656 $\pm$ 0,031	0,306 $\pm$ 0,023	0,386 $\pm$ 0,024	0,999 $\pm$ 0,002	0,001 $\pm$ 0,002
CORN	0,832 $\pm$ 0,008	0,533 $\pm$ 0,044	0,527 $\pm$ 0,036	0,521 $\pm$ 0,027	0,527 $\pm$ 0,036	0,168 $\pm$ 0,008	0,307 $\pm$ 0,044	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax eq. (argmax)	0,828 $\pm$ 0,006	0,510 $\pm$ 0,013	0,514 $\pm$ 0,037	0,505 $\pm$ 0,025	0,514 $\pm$ 0,037	0,172 $\pm$ 0,006	0,290 $\pm$ 0,051	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax eq. (mediana)	0,828 $\pm$ 0,007	0,511 $\pm$ 0,012	0,509 $\pm$ 0,040	0,503 $\pm$ 0,029	0,509 $\pm$ 0,040	0,172 $\pm$ 0,007	0,284 $\pm$ 0,054	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000

Tabla X: Resultados completos para GDS_R5: cinco folds externos.

Modelo	Acc.	Prec.	Rec.	F1	BalAcc	MAE	QWK	Acc. ± 1	Err. ≥ 2
Softmax (def.)	0,775 $\pm$ 0,010	0,515 $\pm$ 0,017	0,513 $\pm$ 0,017	0,506 $\pm$ 0,016	0,513 $\pm$ 0,017	0,225 $\pm$ 0,010	0,433 $\pm$ 0,030	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax (HP)	0,778 $\pm$ 0,009	0,522 $\pm$ 0,016	0,516 $\pm$ 0,015	0,510 $\pm$ 0,015	0,516 $\pm$ 0,015	0,222 $\pm$ 0,009	0,440 $\pm$ 0,027	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
CORAL	0,658 $\pm$ 0,035	0,576 $\pm$ 0,035	0,629 $\pm$ 0,043	0,589 $\pm$ 0,037	0,629 $\pm$ 0,043	0,346 $\pm$ 0,036	0,496 $\pm$ 0,050	0,996 $\pm$ 0,003	0,004 $\pm$ 0,003
CORAL + pesos	0,658 $\pm$ 0,035	0,576 $\pm$ 0,035	0,629 $\pm$ 0,043	0,589 $\pm$ 0,037	0,629 $\pm$ 0,043	0,346 $\pm$ 0,036	0,496 $\pm$ 0,050	0,996 $\pm$ 0,003	0,004 $\pm$ 0,003
CORN	0,772 $\pm$ 0,009	0,514 $\pm$ 0,019	0,505 $\pm$ 0,012	0,500 $\pm$ 0,012	0,505 $\pm$ 0,012	0,228 $\pm$ 0,009	0,420 $\pm$ 0,020	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax eq. (argmax)	0,777 $\pm$ 0,007	0,523 $\pm$ 0,012	0,509 $\pm$ 0,011	0,505 $\pm$ 0,010	0,509 $\pm$ 0,011	0,223 $\pm$ 0,007	0,428 $\pm$ 0,018	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000
Softmax eq. (mediana)	0,778 $\pm$ 0,006	0,528 $\pm$ 0,011	0,510 $\pm$ 0,010	0,507 $\pm$ 0,009	0,510 $\pm$ 0,010	0,222 $\pm$ 0,006	0,430 $\pm$ 0,017	1,000 $\pm$ 0,000	0,000 $\pm$ 0,000

APÉNDICE B

RÚBRICA DE AUTOEVALUACIÓN

Tabla XI: Autoevaluación del trabajo presentado.

Criterio	¿Cumplido?
Introducción clara	Sí
Marco teórico adecuado	Sí
Metodología detallada	Sí
Resultados completos y visuales	Sí
Discusión crítica	Sí
Conclusiones reflexivas	Sí
Calidad y estructura del código	Sí
Presentación clara y sin errores	Sí
Reproducibilidad	Sí
Aportes adicionales	Sí